



NHN NAN2026 해커톤 · AI 활용 기술 문서

그날, 마을에서

7명의 NPC 전원이 실시간 Claude 호출로 말하고, 기억하고, 소문을 흘리고, 자백한다.

구조 · 프롬프트 설계 · 외부 에셋 출처

목차

- 1 시스템 아키텍처
- 2 모델 구성
- 3 페르소나 생성 — NPC마다 한 번
- 4 실시간 대화 설계
- 5 그 외 실시간 콘텐츠 생성 (7종)
- 6 안전성 · 신뢰성 설계
- 7 외부 에셋 출처
- 8 기술 스택 요약

이 문서에 인용된 프롬프트 원문은 `llm-proxy/src/main/java/.../service/LlmService.java`에서 그대로 발췌했다. 실제 배포 코드와 동일하다.

1 시스템 아키텍처

게임은 3개 서비스로 분리되어 있다. **llm-proxy**는 backend 전용 내부 API 서버로, 프론트엔드가 직접 호출하지 않고 항상 backend를 경유한다 (InternalApiKeyFilter로 /internal/** 전체를 내부 API 키로 보호).

frontend React + Phaser · Vite 플레이어 입력, 대화 UI, 상태 표시	backend Spring Boot 게임 상태·세션·DB, llm-proxy 호출 오케스트레이션	llm-proxy Spring Boot + Anthropic Java SDK Claude 호출 전담, 프롬프트·폴백·안전장치
---	--	--

llm-proxy가 노출하는 내부 엔드포인트는 9개다.

엔드포인트	역할
POST /internal/llm/persona/generate	세션 시작 시 NPC별 상세 페르소나 1회 생성
POST /internal/llm/dialogue	실시간 대화 응답 + 호감도 변화량 산출
POST /internal/llm/event	오답 고발 직후 랜덤 이벤트 연출 텍스트
POST /internal/llm/sabotage-summary	밤 사보타주 다음날 아침 소문 텍스트
POST /internal/llm/gift-reaction	선물 수령 시 NPC 반응 대사
POST /internal/llm/wrong-accusation	오답으로 지목된 무고한 NPC의 억울함 토로
POST /internal/llm/ending	정답 고발 성공 시 범인의 개별 엔딩 스토리
POST /internal/llm/clue	단서 카드 문구 생성 (애매하게 설계)
POST /internal/llm/clue/clarify	돋보기 사용 시 단서 문구 명확화

2 모델 구성

용도	모델	선택 이유
대화(chat)	claude-sonnet-5	플레이어가 매 턴 응답을 기다리는 구간이라 체감 속도가 가장 중요. thinking 비활성화로 지연 추가 절감
페르소나·엔딩·단서·이벤트 등 나머지 전부	claude-opus-5	실시간성보다 서사 품질이 중요한 생성 작업

모델명은 LLM_MODEL / LLM_CHAT_MODEL 환경변수로 교체 가능.

3 페르소나 생성 — NPC마다 한 번

세션이 시작되면 NPC 7명 각각에 대해 딱 한 번, 기본 정보(이름·역할·나이·성격 요약·말투·예시 대사)와 범인 여부·동기(초안)를 입력으로 넣어 상세 배경 서사를 **구조화 출력(JSON Schema)**으로 생성한다. 결과는 세션 동안 캐싱되어 재생성되지 않는다.

SYSTEM PROMPT (발췌)

당신은 마을 사보타주 추리 게임의 NPC 페르소나를 설계하는 작가입니다.
주어진 NPC 기본 정보를 바탕으로, 대화용 LLM이 이 캐릭터를 실시간으로 연기할 때
참고할 수 있는 구체적인 배경 서사와 예시 대사를 만들어주세요.
범인으로 배정된 NPC라면(동기가 주어짐) 그 동기를 배경 서사와 자연스럽게 엮어
구체화하되, 너무 노골적으로 죄를 암시하지는 마세요.

실패 시(네트워크 오류, 응답 거부 등) 조용히 **정적 폴백 페르소나**(기본 정보 그대로)로 대체되어 게임 진행 자체는 끊기지 않는다. 페르소나 생성 호출은 실측 지연이 커서(~23초) 요청 타임아웃을 대화(30초)보다 넉넉한 40초로 별도로 지정했다.

4 실시간 대화 설계

4-1. 프롬프트 캐싱

캐릭터 시트(이름·성격·말투·배경)는 같은 세션 안에서 이 NPC와 나누는 모든 턴에 걸쳐 토씨 하나 안 바뀐다. 이 블록에 `cache_control: ephemeral` 브레이크포인트를 걸어, 같은 NPC와 대화를 이어갈수록(하루 최대 3턴) 이 부분만큼의 입력 토큰을 캐시로 대체해 비용·지연을 줄인다. 턴마다 바뀌는 내용(호감도·목적담·마을 소식)은 별도 블록으로 뒤에 붙여 캐시 적용을 깨지 않는다.

4-2. 호감도 구간별 톤 가이드

대화 시작 전, 현재 호감도 점수를 3구간으로 나눠 각기 다른 태도 지시를 시스템 프롬프트에 주입한다.

호감도	지시 내용 (발췌)
70점 이상	"플레이어에게 우호적이고 친근한 태도로 답하고, 본인이 알고 있는 단서나 정보가 있다면 먼저 나서서 알려 주려는 태도를 보이세요."
30~70점	"예의는 지키되 아직 특별히 친하지는 않은 사이입니다. 단서나 민감한 정보를 스스로 먼저 꺼내지는 마세요."
30점 미만	"대화를 짧고 무뎌둑하게 회피하려는 태도를 보이세요. [...] 질문에 비협조적으로 얼버무리거나, 사실을 살짝 다르게 말하거나 둘러대는 등 완전히 솔직하지 않은 태도를 보여도 됩니다."

4-3. 목적담 — 직접 목적과 소문 전파를 구분

사보타주가 일어난 밤, 근처에 있던 NPC에게는 "무엇을 봤는지"는 알려주지 않고 "그 자리에 있었다"는 설정만 준다 — 캐릭터가 스스로 애매하게 지어내되 범인을 특정하지 못하게 하기 위함이다. 2차 전파(가까운 관계·마을 소식통을 경유해 들은 경우)에는 "~라고 들었다"는 전언 투로 말하도록 별도 지시를 준다.

4-4. 정직 모드 · 추리 대화 제한

거짓말탐지기 사용 시 "정직 모드" 지시가, 7일차 이후에는 "추리 관련 질문은 캐릭터답게 얼버무리라"는 지시가 추가로 시스템 프롬프트에 삽입된다. 두 지시가 충돌하면(정직 모드가 걸린 알리바이 질문) 정직 모드가 우선하도록 명시한다.

4-5. 호감도 변화량 산출

매 응답과 함께 Claude가 "방금 발화가 호감도에 어떤 영향을 줬는지"까지 -5~+5 범위로 함께 판단해 반환한다. JSON Schema는 숫자 범위(min/max)를 강제할 수 없어 애플리케이션 코드에서 방어적으로 clamp한다.

...실제 게임 밸런스상 한 턴의 변화 폭은 보통 작습니다 - 평범한 대화는 -2~+3 정도,
뚜렷하게 무례하거나 인상적인 경우에만 그보다 큰 값을 쓰세요.

5 그 외 실시간 콘텐츠 생성 (7종)

대화 외에도 게임의 거의 모든 서술형 텍스트가 그때그때 Claude로 생성된다 — 미리 써둔 고정 문구가 아니라, 매 판 랜덤 배정된 범인·상황에 맞춰 매번 새로 만들어진다.

기능	트리거 시점	설계 포인트
사보타주 아침 요약	매일 밤 사보타주 직후	범인을 특정할 정보(외형·이름) 없이 장소·유형만으로 서술
단서 카드 생성	단서 습득 시	실제 범인의 외형 묘사를 참고하되, 주제별(머리카락/소지품/발자국/혈흔/자국) 가이드에 따라 일부러 애매하게 작성
단서 명확화	돋보기 사용	기존 문구에 외형 묘사 기반 디테일 1개만 추가
오답 이벤트 연출	7→8, 8→9일차 오답 시	진범 정보는 아예 전달하지 않아 특정 인물을 암시할 수 없음
오답 고발 반응	오답으로 지목된 직후	지목된 NPC는 실제로 무고하므로 성격에 맞는 억울함 연출
선물 반응	선물 세트 사용	성격·말버릇 반영한 1인칭 짧은 감사 반응
엔딩 스토리	정답 고발 성공	동기·저지른 사보타주 유형을 반영해 4~6문장 자백형 서사

6 안전성 · 신뢰성 설계

- **안전 정책 거부(Refusal) 감지** — Claude가 `stop_reason: refusal`로 응답을 거부하면 예외로 걸러 폴백 로직으로 자연스럽게 넘어간다. (개발 중 `Optional<StopReason>`을 `Object`로 잘못 받아 이 체크가 사실상 무력화돼 있던 버그를 테스트 작성 과정에서 발견해 수정했다.)
- **정적 폴백 문구** — 9개 생성 기능 전부, LLM 호출이 실패해도 게임 진행이 끊기지 않도록 각 상황에 맞는 대체 문구를 준비해뒀다.
- **사용량 로깅** — 호출 지점별로 input/output/cache 토큰 사용량을 로그로 남겨, 어떤 기능이 비용을 얼마나 쓰는지 Anthropic 콘솔을 직접 보지 않고도 확인할 수 있다. `cacheRead > 0`이면 프롬프트 캐싱이 실제로 적중했다는 뜻이라 캐싱 효과를 이 로그만으로 검증한다.
- **타임아웃 분리** — 대화는 30초, 페르소나 생성은 40초로 별도 타임아웃을 두어 실시간성이 중요한 대화가 느린 생성 작업에 발목 잡히지 않게 했다.

7 외부 에셋 출처

NPC 캐릭터, 배경·건물·시설·가구·아이템·UI 아트는 전부 코덱스(Codex, OpenAI 이미지 생성 도구)로 제작했다. 캐릭터별로 외형(머리카락·체격·복장 등)을 영어 프롬프트로 구체적으로 지정해 생성했으며, 이 프롬프트 원문은 기타/2. 에셋/NPC/*/metadata.json에 보관되어 있고 일부는 단서 카드 생성 프롬프트의 재료로도 재사용된다.

전달된 게임 자산은 **73개 중 73개 전량 검수 통과**(누락·손상·빈 투명 이미지 0건) — 지형 7종, 농작물 5종×3단계, 과일 4종×3단계, 주택 7채, 공용 건물 3종, 상태별 시설 5종, 마을 오브젝트 11종, 가구 8종, 아이템 5종.

8 기술 스택 요약

영역	스택
프론트엔드	React + Phaser.js (Vite), TypeScript
백엔드	Spring Boot 4.1.0 (Java 21), MySQL 8.0
AI 연동	Spring Boot 기반 별도 llm-proxy 서비스, Anthropic Java SDK 2.34.0
AI 모델	claude-opus-5 (서사 생성) / claude-sonnet-5 (실시간 대화)
인프라	Docker Compose(MySQL 로컬), Gradle Wrapper